

Método estadístico retroactivo

Cómo se decide qué números del cuaderno de laboratorio son defendibles

Marco de inferencia, 2026-07-21T13:10Z

Realizado por Javier Francisco Dibo Gómez

Índice de contenidos

1. El problema que resuelve este documento

1.1 Lo que este marco NO es

2. Tres modos de fallo que el marco vigila

2.1 Diseño equivocado

2.2 Pseudo-replicación

2.3 Diseños que nunca pudieron responder a su pregunta

3. Qué prueba se aplica a qué diseño

3.1 Una trampa que el marco bloquea explícitamente

4. Empates y pruebas que no existen

5. Cuando solo sobreviven los marginales

6. Multiplicidad

7. Estado de los datos: tres niveles

8. Reproducir el análisis

Índice de tablas

Tabla 2.1: Cuántos pares discordantes en una sola dirección hacen falta para alcanzar $\alpha = 0,05$ bilateral

Tabla 3.1: Regla de selección de prueba por diseño experimental

Tabla 7.1: Niveles de disponibilidad de datos y qué permite afirmar cada uno

Índice de bloques de código

Bloque de código 2.1: Corrección por efecto de diseño aplicada antes de cualquier intervalo o p-valor

Bloque de código 8.1: Comandos que regeneran el análisis completo desde el registro de afirmaciones

1. El problema que resuelve este documento

El proyecto se llevó como un cuaderno de laboratorio. Cada campaña pre-registraba una puerta ("WSEL debe despejar 4/5"), ejecutaba el brazo, comparaba el recuento con la puerta a ojo y anotaba un YES o un NO. Como forma de dirigir un programa de investigación es legítima y funcionó: encontró la palanca del contrato de entrega, descartó la super-resolución, mató la palanca de capacidad.

Como forma de defender una afirmación en un TFM no vale. Una búsqueda por `mcnemar | binomtest | scipy.stats | statsmodels | wilson | p-value` sobre el repositorio completo devolvía **cero ficheros** antes de este trabajo. Había decisiones tomadas con n entre 2 y 6, sin intervalo de confianza, sin corrección por multiplicidad y sin una sola prueba de hipótesis.

Este documento define el marco con el que se re-analizan esas campañas. La implementación está en `grounding/stats.py` y su comportamiento está fijado por `tests/test_stats.py`.

1.1 Lo que este marco NO es

No es un intento de convertir NOs en YESes. Añadir p-valores a posteriori es barato y casi siempre inútil. **La parte difícil, y la razón de que este módulo exista, es negarse a calcular los que engañarían.** Buena parte de lo que sigue son reglas de rechazo, no de cálculo.

Tampoco es un re-análisis exploratorio. Las puertas ya estaban pre-registradas; lo que se añade es la incertidumbre que siempre debió acompañarlas, no una segunda oportunidad de encontrar un efecto.

2. Tres modos de fallo que el marco vigila

2.1 Diseño equivocado

McNemar exige que los **mismos elementos** se midan bajo ambos brazos. Aplicarlo a dos grupos independientes infla la significación. La implementación recibe únicamente los recuentos discordantes, de modo que un conjunto no pareado no puede llegar a la función por descuido; y `discordant_counts()` **descarta** los elementos que solo aparecen en un brazo, porque contar una ejecución que falló como un fracaso del brazo es cómo una caída se convierte en un resultado.

2.2 Pseudo-replicación

"6 clips x 2 repeticiones" son 6 observaciones, no 12. Cinco celdas recortadas del mismo vídeo no son cinco ensayos independientes. Miles de frames consecutivos de un único vuelo son **un** vuelo: están autocorrelacionados, y tratarlos como $n = 30.000$ es la forma clásica de fabricar significación a partir de un solo ensayo. Toda afirmación lleva `n_effective` separado de `n_rows`, y el informe imprime los dos junto con la razón por la que difieren.

Separarlos no basta: hay que **usar** el que corresponde. Un intervalo calculado sobre `n_rows` y etiquetado con `n_effective` es peor que no dar intervalo, porque reclama una precisión que nunca se compró. Ocurrió durante la propia redacción de este marco — E17 imprimía `n = 1` junto a un IC de $[0,000, 0,278]$ construido con 10 filas de un mismo fallo determinista — y de ahí sale `deflate_to_effective()`:

```
k, n = deflate_to_effective(k_observado, n_filas, n_effective)
```

Bloque de código 2.1: Corrección por efecto de diseño aplicada antes de cualquier intervalo o p-valor

Conserva la proporción y sustituye el denominador por `n_effective`. Es una corrección por efecto de diseño con `deff = n_rows / n_effective`, y es deliberadamente tosca: **solo puede ensanchar el intervalo y debilitar el p-valor, nunca al revés**, de modo que no puede fabricar un resultado. Con la corrección aplicada, E17 pasa a $[0,000, 0,793]$ sobre $n = 1$, que es lo que realmente sostiene una única observación. El informe marca cada caso afectado con `[deflactado desde k/n]` para que la deflación sea visible y no un ajuste silencioso.

2.3 Diseños que nunca pudieron responder a su pregunta

Es el aporte principal del marco y el más incómodo.

Una comparación pareada de 5 elementos **no puede** alcanzar $p < 0,05$ bilateral aunque los cinco pares volteen a favor: el suelo es $p = 0,0625$. Un $n = 6$ llega justo, y solo si el resultado es perfecto (6 de 6 discordantes en la misma dirección, $p = 0,031$).

Pares (n)	Discordantes necesarios	Se puede alcanzar
5	—	No, con ningún resultado
6	6 (todos)	Solo si es perfecto
12	6	Sí
25 / 26	6	Sí
56	6	Sí

Tabla 2.1: Cuántos pares discordantes en una sola dirección hacen falta para alcanzar $\alpha = 0,05$ bilateral

La consecuencia es dura y hay que decirla: **un NO salido de un diseño de $n = 5$ no es evidencia de ausencia de efecto, es evidencia de ausencia de experimento.**

`min_discordant_for_significance()` lo calcula a partir de **n solo**, sin mirar el resultado, que es lo que lo hace legítimo a posteriori — a diferencia de la "potencia observada", que no es más que el p-valor recalculado.

El mismo argumento vale para las puertas de una sola proporción. Con $n = 25$, una puerta pre-registrada del **90 %** es inalcanzable en términos estadísticos: un 25/25 perfecto da $p = 0,9^{25} = 0,072$. Una puerta así solo puede despejarse descriptivamente.

3. Qué prueba se aplica a qué diseño

La elección la fija el **diseño**, nunca el p-valor que sale.

Diseño	Prueba	Por qué esta y no otra
Binario pareado (mismos clips, dos brazos)	McNemar exacto	Exacto y no ji-cuadrado: con $b + c \leq 5$, que es lo habitual aquí, la aproximación no vale
Binario de un brazo contra una puerta	Binomial exacta + intervalo de Wilson	La puerta es una probabilidad, no un recuento
Binario no pareado	Fisher exacta	Grupos independientes
Continuo pareado (latencias, IoU, error de píxel)	Wilcoxon de rangos con signo + IC bootstrap	Las latencias tienen cola derecha y n es pequeño: la normalidad de una t haría un trabajo que no se ha ganado
Sin hipótesis pre-registrada	Solo intervalo de Wilson	Descriptivo, y etiquetado como tal

Tabla 3.1: Regla de selección de prueba por diseño experimental

Todo exacto. Ninguna aproximación normal: con estos n , ni la McNemar ji-cuadrado ni el intervalo de Wald serían correctos, y las versiones exactas no cuestan nada. Wald además falla justo donde vive este repositorio — en 24/25 da un límite superior por encima de 1, y en 0/6 colapsa a $[0, 0]$, afirmando certeza absoluta a partir de seis observaciones.

3.1 Una trampa que el marco bloquea explícitamente

Sobre las cifras de P5.2 la prueba **no pareada** de Fisher da un p **menor** ($1,2e-05$) que la McNemar pareada ($3,1e-05$), porque McNemar descarta los 9 clips concordantes y saca toda su potencia de los 16 discordantes. Es tentador reportar Fisher.

Sería p-hacking por selección de prueba. Los 25 clips se midieron bajo ambos brazos, luego las observaciones están pareadas y la prueba se deduce del diseño. `tests/test_stats.py` fija esta relación con una aserción para que una sesión posterior no pueda cambiar en silencio al p-valor más bonito y llamarlo mejora.

4. Empates y pruebas que no existen

Tres campañas de simulación terminaron en empate casi perfecto (24/24 contra 24/24, 24/24 contra 23/24, 56/56 contra 55/56). Devolver $p = 1,0$ en el caso del empate exacto se leería como "probado, brazos equivalentes". No lo es: son **0 pares discordantes**, es decir, ausencia de prueba en cualquier dirección. `mcnemar(0, 0)` devuelve `NaN` a propósito y el informe lo imprime como `indefinido`.

Un único par discordante — el caso de 23/24 y 55/56 — da exactamente $p = 0,5$. Es la demostración más limpia posible de que esas campañas no podían separar los brazos, con independencia de lo que hubiera salido.

5. Cuando solo sobreviven los marginales

A veces se conserva el total de cada brazo pero no el pareo elemento a elemento, de modo que b y c no son recuperables. La salida fácil sería descartar la afirmación; la correcta es **acotarla**.

Los marginales fijan $b - c$. Basta recorrer todos los pares (b, c) compatibles con esa diferencia y quedarse con el **peor** para la significación: el p-valor resultante es una cota superior válida bajo cualquier pareo consistente con los datos. Si esa cota ya cae por debajo de α , la conclusión no depende del pareo perdido.

Es lo que rescata el resultado más fuerte de la Parte I. En HF contra GGUF los marginales dan $b - c = 30$, luego c está en $[0, 15]$; el peor caso, $c = 15$ y $b = 45$, todavía da **$p = 1,3e-04$** . La catástrofe de exportación es significativa se pareara como se pareara. En `claims.json` se almacenan los b y c del peor caso precisamente para que el número publicado sea la cota, nunca la versión favorable.

6. Multiplicidad

El repositorio corrió decenas de comparaciones con puerta a lo largo de seis partes. Reportarlas todas sin corregir invita a la objeción evidente: una de cada veinte despeja por azar. Se aplica **Holm-Bonferroni** sobre la familia de afirmaciones con puerta.

Holm y no Bonferroni porque es uniformemente más potente al mismo error por familia; y no Benjamini-Hochberg porque estas son puertas confirmatorias y no un cribado. Las pruebas indefinidas (NaN) quedan **fuera** de la familia: una prueba que no ocurrió no puede consumir alfa.

7. Estado de los datos: tres niveles

Cada afirmación se clasifica por lo que sobrevive en disco, y la clasificación determina lo que puede decirse de ella.

Nivel	Significa	Qué permite
<code>per_item</code>	Existe un registro por elemento con su resultado, y se abrió	Prueba pareada real, IC, recuentos discordantes b y c
<code>counts_only</code>	Solo sobrevive el agregado del README	Prueba a partir de recuentos si el pareo es conocido; sin IC por elemento
<code>missing</code>	No hay datos crudos	Ninguna. Va a la cola de re-ejecución

Tabla 7.1: Niveles de disponibilidad de datos y qué permite afirmar cada uno

Una afirmación en `missing` no se defiende en el TFM. Se declara como pendiente y se re-ejecuta, o se retira. El registro de re-ejecución vive en `thesis/rerun-backlog.md` con el comando exacto de cada una.

8. Reproducir el análisis

```
.venv-ft/bin/python -m grounding.stats          # auto-  
comprobación del módulo  
.venv-ft/bin/python -m pytest tests/test_stats.py # 33 aserciones de  
regresión  
.venv-ft/bin/python thesis/run_stats.py         # regenera el  
informe y la figura
```

Bloque de código 8.1: Comandos que regeneran el análisis completo desde el registro de afirmaciones

El informe es un derivado: se regenera del registro de afirmaciones y no se edita a mano.