

LLMs y VLMs locales en hardware de borde

Resumen técnico de progreso para la tesis de máster

Jetson Orin Nano 8 GB — Partes I, II y III · 25 de junio de 2026

Realizado por Javier F. Dibo Gómez

Índice de contenidos

1. 1. Resumen ejecutivo

2. 2. Parte I — Exploratoria (congelada)

2.1 2.1.1 Campañas de benchmark del dispositivo

2.2 2.2.2 Fine-tune de grounding con VLM (Stages 1–4)

3. 3. Parte II — Reconstrucción principista v2 (completa)

4. 4. Parte III — Seguimiento persistente / permanencia de objeto v3 (completa)

4.1 4.1.1 La arquitectura forzada por el hardware

4.2 4.2.2 Las cinco puertas temporales (T0–T4, todas PASS)

5. 5. Las dos contribuciones transversales

Índice de tablas

Tabla 1.1: Las tres partes del cuaderno de un vistazo.

Tabla 2.1: Extracto del barrido de 10 modelos (decodificación, eficiencia, térmica).

Tabla 3.1: Las cinco fases v2 y su veredicto.

Tabla 3.2: Predicciones reales del modelo Q8_0 desplegado frente a verdad-terreno.

Tabla 4.1: Resultado de cada fase de la Parte III.

Tabla 5.1: Cifras de cabecera para presentar.

1. 1. Resumen ejecutivo

Este informe resume el estado de una tesis de máster sobre **ejecución de modelos de lenguaje y de visión-lenguaje (VLM) localmente en hardware de borde** — una NVIDIA Jetson Orin Nano con solo 8 GB de memoria unificada, a 15 W con relojes fijados. El trabajo se organiza como un cuaderno de laboratorio en tres partes, cada una con puertas (*gates*): ninguna fase empieza hasta que la anterior está en verde y documentada.

Los resultados de cabecera son tres:

- **Envolvente de rendimiento del borde:** caracterización completa de 0,5 B a 8 B de parámetros — de **71,5 a 7,7 tok/s** de decodificación, con la energía y la térmica medidas. Los 8 GB son el límite duro de capacidad (un modelo de 12 B da OOM).
- **Anclaje de lenguaje desplegado:** un modelo de *grounding* aéreo de una sola imagen, **Qwen2-VL-2B Q8_0, IoU@0,25 = 62,6 %** ejecutándose en el propio dispositivo — ~3,1× el resultado exploratorio previo (19,5 %) sobre la misma tarea.
- **Seguimiento persistente con permanencia de objeto:** lock sobre un objetivo en movimiento a través de oclusiones, validado en bucle cerrado (Parte III, T0–T4 todas GATE PASS).

La contribución metodológica central es haber **identificado y eliminado una brecha de fidelidad de despliegue** (–23 pp ocultos en la capa de *runtime*, no en la cuantización) que aparecía solo *después* de entrenar.

Parte	Pregunta	Estado	Resultado de cabecera
I — Exploratoria	¿Qué aguanta el dispositivo? ¿Se puede <i>groundear</i> ?	Congelada	Envolvente 0,5–8 B + Stages 1–4
II — Reconstrucción v2	¿Dónde está el objeto que nombra la frase, en esta imagen?	Completa	IoU@0,25 = 62,6 % desplegado
III — Permanencia v3	¿Mantengo el lock sobre ese objeto en movimiento?	Completa	71,5 % cobertura en SITL en vivo

Tabla 1.1: Las tres partes del cuaderno de un vistazo.

Todas las medidas: **Jetson Orin Nano 8 GB, 15 W con relojes fijados** (`nvpmodel -m 0 + jetson_clocks`), **llama.cpp commit 57fe1f0** , **CUDA sm_87**.

2. 2. Parte I — Exploratoria (congelada)

La Parte I estableció la envolvente de rendimiento del hardware y un primer intento de *grounding* con VLM. Es el registro histórico, ya congelado.

2.1 2.1 Campañas de benchmark del dispositivo

Un barrido de 10 modelos (0,5 B – 8 B, todos Q4_K_M, relojes fijados) midió la decodificación, el prefill, la energía y la térmica con `tegrastats` durante toda la ventana de inferencia.

Modelo / cuant.	Params	pp512 tok/s	tg128 tok/s	tok/s·W ⁻¹	Pico °C
Qwen2.5-0.5B Q4_K_M	0,5 B	3027	71,52	11,77	59,9
Llama-3.2-3B Q4_K_M	3,0 B	570	14,60	2,00	65,1
Mistral-7B-v0.3 Q4_K_M	7,2 B	253	8,39	0,98	67,3
Meta-Llama-3.1-8B Q4_K_M	8,0 B	245	7,75	0,89	67,4

Tabla 2.1: Extracto del barrido de 10 modelos (decodificación, eficiencia, térmica).

La eficiencia recorre **11,8 → 0,9 tok/s·W⁻¹** y el pico de temperatura del SoC se mantiene en $\leq 67\text{ °C}$ sin *throttling* térmico observado. Un **resultado negativo** documentado:

Gemma-3-12B QAT no carga — OOM de CUDA (pesos ~7,7 GiB > VRAM libre). Esto fija los 8 GB de memoria unificada como el límite de capacidad vinculante.

2.2 2.2 Fine-tune de grounding con VLM (Stages 1–4)

Tarea: expresión referente → caja delimitadora (un *box* por frase).

- **Stage 2 (RefDrone):** colapso de modo (IoU@0,25 $\approx 1\%$), causado por un dataset mal planteado.
- **Stage 3 (RefCOCO, metodología corregida):** PASS, IoU@0,25 = **82,5 %** (HF bf16).
- **Stage 4 (currículo RefDrone):** fallo por poco, **19,5 %** frente a una puerta del 20 % — una frontera de capacidad/presupuesto, no un colapso.

El hallazgo clave de la Parte I se convierte en una **restricción vinculante**: una *brecha de fidelidad de despliegue*. La habilidad exportada cayó HF bf16 85 % → GGUF F16 62 % → Q8_0 55 %. La pérdida de **-23 pp** es una **divergencia del preprocesado de imagen Idefics3 en**

llama.cpp (runtime); solo -7 pp son cuantización. La penalización del *runtime* domina y se descubrió *después* de entrenar.

3. 3. Parte II — Reconstrucción principista v2 (completa)

Una reconstrucción deliberada del *grounding* de una sola imagen, diseñada **hacia atrás desde el despliegue** y organizada en torno a **un único contrato compartido**: el prompt, el parser y la métrica IoU/ `center_std` viven en un solo fichero (`contract.py`) e se importan en todas partes, de modo que prompt/parser/métrica nunca pueden volver a divergir. Cadena de herramientas gestionada: `uv` con *lockfile* fijado, manifiestos por ejecución, contrato bloqueado con `pytest` y commit de llama.cpp fijado.

Cinco fases con puerta, **todas PASS**:

Fase	Qué hace	Veredicto
0 — fidelidad primero	Elegir el <i>spine</i> por los números, no por opinión	Qwen2-VL-2B (fidelidad ~8× mejor que SmolVLM)
1 — auditoría de datos	Distribución de cajas/tamaños antes de gastar GPU	PASS
2 — resolución	Resolución como variable pre-registrada	PASS
3 — entrenamiento	Un único LoRA dirigido por config	IoU@0,25 = 59,5 % (3× la puerta)
4 — export y despliegue	GGUF Q8_0 en la Jetson	IoU@0,25 = 62,6 %

Tabla 3.1: Las cinco fases v2 y su veredicto.

Lo decisivo de la Fase 4: el modelo **desplegado supera** a la referencia HF (la brecha de *runtime*/preprocesado pasa a ser neta positiva: -2,7 pp runtime, -0,5 pp cuantización). **La catástrofe de fidelidad de la Parte I queda eliminada.**

Frase	Caja predicha	Caja verdad-terreno	Solape
"Los coches negros en el cruce."	[266, 476, 346, 644]	[268, 481, 343, 652]	IoU ≈ 0,9
"Los coches azules a la izquierda de la calle."	[324, 267, 341, 299]	[325, 263, 342, 294]	IoU ≈ 0,9

Tabla 3.2: Predicciones reales del modelo Q8_0 desplegado frente a verdad-terreno.

El producto de la Parte II es un **anclaje** (*anchor*) de lenguaje desplegable que corre en la propia Orin.

4. 4. Parte III — Seguimiento persistente / permanencia de objeto v3 (completa)

La Parte III pasa de un *fotograma* a un *flujo de vídeo*: mantener el lock sobre un objetivo en movimiento a través de oclusión, cambio de escala, *motion blur* y salidas breves del encuadre, lo bastante bien como para cerrar un bucle de seguimiento de dron. Las métricas de cabecera pasan a ser **temporales** (continuidad de pista, cambios de identidad, re-adquisición, cobertura, error de seguimiento en bucle cerrado).

4.1 4.1 La arquitectura forzada por el hardware

Una pasada del VLM en la Orin es de ~0,3–1,2 Hz, pero un bucle de seguimiento necesita ~20 Hz — una brecha estructural de 20–60×. Por eso v3 ejecuta un **tracker rápido por fotograma a 20 Hz que sostiene el lock**, con el **VLM como anclaje semántico asíncrono y esporádico** para adquisición y re-adquisición.

4.2 4.2 Las cinco puertas temporales (T0–T4, todas PASS)

Fase	Qué resuelve	Resultado
T0 — cadencia y dinámica	Medir antes de diseñar; elegir el <i>spine</i> del ancla	Qwen2-VL-2B Q8_0 @512, re-adq. por evento
T1 — contrato temporal	Clips SITL + métricas temporales bloqueadas en pytest	PASS
T2 — permanencia	Memoria de apariencia contra el re-lock del objeto equivocado	ID sw 1→0, pureza 0,725→1,000
T3 — bucle cerrado	Batir el negativo de la Phase-C sobre objetivo móvil	≈0 % → 71,5 % SITL en vivo
T4 — despliegue en Orin	Verificar ambas capas sobre el metal	tracker 20 Hz, ancla 0,44 Hz, 100 % parse

Tabla 4.1: Resultado de cada fase de la Parte III.

La **T2 es la pieza genuinamente novedosa**: el *ByteTrack* base es un Kalman de velocidad constante **sin memoria de apariencia**, así que re-engancha el objeto *equivocado* tras una oclusión. Añadiendo un descriptor de apariencia en la adquisición y re-adquiriendo por

mínima distancia de descriptor, los cambios de identidad pasan de **1 a 0** y la pureza de identidad de **0,725 a 1,000** por encima del codo de separabilidad.

La **T3** bate directamente el resultado negativo de la Parte I (la Phase-C daba cobertura ≈ 0 % sobre un objetivo en movimiento) elevándola a **97,6 % cinemático / 71,5 % en SITL ArduCopter en vivo**.

El producto de la Parte III es seguimiento persistente de objetivo móvil con permanencia de objeto, validado de extremo a extremo en SITL y en el dispositivo. Una GUI de demo de tres pestañas ejecuta el pipeline real de dos capas (subir vídeo + frase $\rightarrow$ salida *trackeada* en la Orin).

5. 5. Las dos contribuciones transversales

El arco de la tesis se sostiene sobre dos hallazgos que cruzan las tres partes.

- **Brecha de fidelidad de despliegue.** Una habilidad VLM exportada puede perder silenciosamente ~23 pp en la capa de *runtime*/preprocesado, con independencia de la cuantización. Se descubrió tarde en la Parte I, se convirtió en una puerta medida *antes* de gastar GPU en la Parte II, y se eliminó.
- **Permanencia de objeto bajo desajuste de tasa impuesto por el hardware.** La brecha de 20–60× entre el VLM y el bucle de control fuerza la división ancla-esporádica + tracker-rápido, y la memoria de apariencia es necesaria para sostener la *identidad* a través de la oclusión. Este es el resultado novedoso de la Parte III.

Eje	Resultado
Envolvente del borde	71,5 → 7,7 tok/s (0,5–8 B); 8 GB es el muro de capacidad
Grounding de una imagen, desplegado	Qwen2-VL-2B Q8_0, IoU@0,25 = 62,6 %
Problema de fidelidad	identificado (–23 pp) y luego eliminado
Permanencia de objeto	pureza 0,725 → 1,000, cambios de ID → 0
Seguimiento en bucle cerrado	Phase-C ≈ 0 % → 71,5 % cobertura SITL en vivo

Tabla 5.1: Cifras de cabecera para presentar.