

Grounding visual anticipatorio para seguimiento de objetivos desde UAV en hardware de borde

Esquema del TFM y mapa de evidencia

Borrador de estructura, 2026-07-21T12:45Z

Realizado por Javier Francisco Dibo Gómez

Índice de contenidos

1. Propósito de este documento

- 1.1 El hallazgo que cambia el plan
- 1.2 Reglas que se aplican a sí mismo
- 1.3 Estado

2. Tesis defendida

3. Estructura propuesta

4. Capítulo 3 — Plataforma, método y métricas

- 4.1 El umbral IoU@0,25
- 4.2 La placa y su techo
- 4.3 El marco de inferencia
- 4.4 El método de desarrollo, acotado
- 4.5 Qué le hizo el re-análisis al cuaderno
- 4.6 La topología real del banco

5. Capítulo 4 — Grounding de un solo frame

- 5.1 Qué se cuenta
- 5.2 Cifras que se citan, con su matiz
- 5.3 La corrección de signo más importante del documento
- 5.4 Advertencia obligatoria sobre RefDrone
- 5.5 Licencias
- 5.6 Figuras

6. Capítulo 5 — Permanencia de objeto

- 6.1 Qué se cuenta
- 6.2 La palanca ROI, dicha con precisión
- 6.3 Cifras de arrastre y de exportación
- 6.4 Dos formulaciones que hay que evitar

6.5 La palanca de super-resolución, descartada

6.6 Figuras

7. Capítulo 6 — El arco de la latencia de adquisición

7.1 Qué se cuenta

7.2 La inferencia que arrastra el resto del documento

7.3 Advertencias que acompañan a cada cifra de este capítulo

7.4 Figuras

8. Capítulo 7 — Grounding anticipatorio

8.1 Estructura interna propuesta

8.2 El estadístico, ya calculado

8.3 Advertencia obligatoria sobre P5.19

8.4 Matices que viajan con los números

8.5 El desvío de simulación

8.6 Figuras

9. Capítulo 8 — Hacia el lazo cerrado

9.1 Qué se cuenta

9.2 Tres cifras de este capítulo que NO deben citarse

9.3 Síncrono contra asíncrono: la distinción que hay que declarar siempre

9.4 Lo que este capítulo NO afirma

9.5 Dos limitaciones del artefacto, para quien lo reutilice

9.6 Dos fallos que merecen media página cada uno

10. Capítulo 9 — Amenazas a la validez

10.1 "Todo corre en la placa" no es lo que se midió

10.2 Composiciones entre máquinas

10.3 Tamaños de muestra e inferencia

10.4 El sim no es el mundo

10.5 Resultados retirados

10.6 Irreproducibilidad de los pesos

11. Capítulo 10 — Conclusiones

12. Deuda de evidencia

13. Anexos previstos

14. Orden de recorte

15. Siguiendo pasos

16. Referencias

Índice de tablas

Tabla 2.1: Las tres afirmaciones subordinadas, el capítulo que sostiene cada una y el límite de esa evidencia

Tabla 3.1: Estructura de capítulos, origen del material y extensión estimada

Tabla 4.1: Resultado global del re-análisis retroactivo de las 65 afirmaciones con puerta

Tabla 8.1: Inferencia post-hoc sobre los resultados con puerta de la Parte V, generada desde los volcados por elemento

Tabla 12.1: Deuda de evidencia previa a la redacción, con el capítulo que bloquea cada partida

Tabla 13.1: Anexos previstos, con el fichero del repositorio que provee cada uno

1. Propósito de este documento

Este no es el TFM. Es el esquema del TFM y, sobre todo, el **mapa entre cada afirmación que se quiere defender y la evidencia que existe en el repositorio para sostenerla** — incluidos los casos, que son muchos, en los que esa evidencia es más débil de lo que sugiere la nota de laboratorio.

Se escribe ahora porque el proyecto tiene el problema contrario al habitual: no falta material, sobra. Seis partes, más de sesenta experimentos registrados, del orden de 272.000 palabras de notas. Un TFM admite unas 60-80 páginas. Eso es una compresión cercana a 10:1, y una compresión de ese factor no se hace escribiendo: se hace **decidiendo qué se tira**. Este documento toma esas decisiones por adelantado y las deja auditables.

1.1 El hallazgo que cambia el plan

Al levantar el inventario aparecieron dos problemas que no son de redacción:

- **No había ni una sola prueba estadística en el repositorio.** Una búsqueda de `mcnemar|binomtest|scipy.stats|statsmodels|wilson|p-value` sobre todos los `.py` y `.md` devolvía cero ficheros. El único estadístico existente era un Spearman escrito a mano, sin p-valor ni intervalo. Varias afirmaciones con puerta descansaban sobre una o tres celdas de diferencia. **Resuelto el 2026-07-21:** el marco está en `grounding/stats.py`, se explica en el Cap. 3 (borrador en `thesis/01-metodo-estadistico.md`), y las 65 afirmaciones con puerta re-analizadas están en `thesis/stats-report.md`. El resultado de ese re-análisis está más abajo y **cambia lo que el TFM puede afirmar**.
- **Las Partes I, II y III no tienen ni un solo directorio proof/**. La regla de entregables por campaña se introdujo en julio y no se aplicó retroactivamente. El resultado individual más fuerte del proyecto — la palanca ROI, que gana en las dos dimensiones a la vez — **no tiene ninguna figura:** existe solo como un JSON de barrido.

Es decir: el trabajo pendiente antes de redactar no es escribir, es **generar la evidencia gráfica que falta y calcular los estadísticos que nunca se calcularon**. Eso está en la Sección "Deuda de evidencia".

1.2 Reglas que se aplican a sí mismo

- Toda cifra citada aquí lleva la máquina en la que se midió. La composición "precisión del 3090 + FPS de la Jetson" en una misma tabla aparece varias veces en el cuaderno y no puede repetirse en el TFM sin decirlo.
- Ninguna figura se planifica sin comprobar si el material existe. Si no existe, se marca **POR GENERAR** y cuesta tiempo, no cero.
- Las advertencias no son opcionales: son las condiciones bajo las cuales las afirmaciones son ciertas. Si una desaparece del texto final, la afirmación correspondiente se vuelve indefendible.
- Se prefiere un resultado negativo bien medido a un resultado positivo mal delimitado.

1.3 Estado

- Bibliografía: `thesis/refs.bib` creada, con las entradas sin verificar marcadas `% VERIFICAR`.
- Esquema: este fichero.
- Texto: no empezado.
- Fecha límite: **sin fijar**. Es la variable que falta y la que ordena todo lo demás.

2. Tesis defendida

Una sola frase, porque si no cabe en una frase no está clara:

Cuando la orden del operador llega a mitad de vuelo y no en el instante cero, la ventana previa a la orden es cómputo gratuito; gastarla en mantener candidatos vivos y limitarse a **seleccionar** al recibir la orden elimina la latencia de adquisición que hace que un sistema de grounding sobre vídeo aéreo entregue una caja ya obsoleta.

De ahí salen tres afirmaciones subordinadas, y cada capítulo empírico existe para sostener una de ellas:

Afirmación	Cap.	Límite de la evidencia
Un VLM de 2B cuantizado hace grounding referencial útil sobre imagen aérea y cabe en un Orin Nano de 8 GB	4-5	Protocolo propio, más fácil que el benchmark publicado
La adquisición en frío es el cuello de botella del sistema integrado, y no se arregla optimizando la adquisición	6	n = 6 clips, todas coches, sin vehículo en el lazo
Anticipar (mantener + seleccionar) sí lo arregla, acotado por la calidad del arrastre	7	El único SÍ a n real cae justo en el listón, p = 0,125

Tabla 2.1: Las tres afirmaciones subordinadas, el capítulo que sostiene cada una y el límite de esa evidencia

La Parte VI (Cap. 8) no sostiene ninguna de las tres todavía.

3. Estructura propuesta

Cap.	Título	Material de origen	Págs. (est.)
1	Introducción y motivación	README.md , propuestas de parte	5
2	Estado del arte	SOURCES.md , surveys, encuesta de datasets	8
3	Plataforma, método y métricas	README.md , grounding/contract.py , 01-metodo-estadistico.md , 02-metodo-multiagente.md	8
4	Grounding de un solo frame	Partes I y II	10
5	Permanencia de objeto	Parte III + E1	9
6	El arco de la latencia de adquisición	Parte IV (E2-E23)	10
7	Grounding anticipatorio	Parte V (P5.1-P5.20)	14
8	Hacia el lazo cerrado	Parte VI (P6.0-P6.1)	6
9	Amenazas a la validez	transversal	6
10	Conclusiones y trabajo futuro	transversal	4

Tabla 3.1: Estructura de capítulos, origen del material y extensión estimada

Total estimado: **80 páginas** de cuerpo. Los agentes que inventariaron cada parte estiman 17 + 26 + 16 + 17 páginas solo para los capítulos 4 a 7 si se contara todo, lo que confirma que el problema es de recorte y no de material.

4. Capítulo 3 — Plataforma, método y métricas

Capítulo corto pero **necesario antes que los empíricos**, porque tres decisiones de medida condicionan todas las cifras posteriores y ninguna es obvia.

4.1 El umbral IoU@0,25

Toda la precisión del proyecto se reporta a IoU@0,25. El estándar de la literatura de comprensión de expresiones referenciales es IoU@0,5. **No existe justificación registrada en ningún sitio del repositorio** para haber elegido 0,25: `grounding/contract.py` declara la constante y apunta a la puerta, sin razón. El TFM tiene que justificarlo explícitamente — presumiblemente porque el objeto aéreo mediano ronda los 16 px y a 0,5 la métrica es inestable — y reportar el IoU medio al lado, que es mucho más sobrio.

Escribir este capítulo sin resolver esto deja un flanco abierto en la primera pregunta del tribunal.

4.2 La placa y su techo

- Jetson Orin Nano 8 GB, **15 W + jetson_clocks**. El modo de 25 W no existe en esta placa: el firmware expone solo 15 W y 7 W, y desbloquearlo exigiría un flasheo de bootloader que se decidió no intentar. Toda cifra de rendimiento es un techo de 15 W, no un techo de silicio.
- Una etiqueta anterior del cuaderno decía "MAXN_SUPER" y **era falsa**; se corrigió el 2026-07-03. No debe reaparecer en el TFM.
- La potencia medida es `VDD_IN` de tegrastats: entrada total de placa, incluido un suelo de plataforma en reposo de ~5,2 W. No es potencia de módulo ni de SoC.

4.3 El marco de inferencia

Sección obligatoria y probablemente la más defendible del capítulo. Borrador completo en `thesis/01-metodo-estadistico.md`; aquí va el resumen y allí el detalle, porque un tribunal preguntará por el método antes que por los números.

Lo que hay que explicar, en este orden:

1. **Qué prueba corresponde a qué diseño**, y que la elección la fija el diseño y nunca el p-valor que sale. Todo exacto: McNemar exacto, binomial exacta, Fisher, Wilcoxon.

Ninguna aproximación normal — con estos n , Wald da $[0, 0]$ para un $0/6$ y un límite superior mayor que 1 para un $24/25$.

2. **`n_effective` frente a `n_rows`**. Seis clips por dos repeticiones deterministas son seis observaciones. Diez ensayos SITL del mismo fallo determinista son uno. 439 captions sobre 316 imágenes no son 439 observaciones independientes. Cada afirmación declara las dos cifras y la razón por la que difieren.
3. **La deflación a n efectivo**. Cuando el denominador cuenta filas y no observaciones independientes, la proporción se conserva y el denominador se sustituye por `n_effective` antes de calcular nada. Es una corrección por efecto de diseño con $\text{deff} = n / n_{\text{effective}}$, deliberadamente tosca: solo ensancha el intervalo y solo debilita el p -valor, luego no puede fabricar un resultado. El caso que la motivó es E17, cuyo $0/10$ daba un intervalo $[0, 0,28]$ sobre diez repeticiones de **un** fallo determinista, y ahora da $[0, 0,79]$ sobre $n = 1$.
4. **Diseños que no podían responder a su pregunta**. Una comparación pareada de cinco elementos no alcanza $p < 0,05$ aunque los cinco volteen: el suelo es $0,0625$. Se calcula desde n solo, sin mirar el resultado, que es lo que lo hace legítimo a posteriori.
5. **Empates y pruebas que no existen**. Cero pares discordantes devuelve `NaN`, no $p = 1,0$.
6. **Multiplicidad**: Holm-Bonferroni sobre la familia de afirmaciones con puerta, con las pruebas indefinidas fuera de la familia.
7. **Los tres niveles de estado de los datos** (`per_item`, `counts_only`, `missing`) y la regla de que una afirmación en `missing` no se defiende: se re-ejecuta o se retira.

4.4 El método de desarrollo, acotado

Subsección corta, con el material extenso en un **Anexo B**. Borrador completo en `thesis/02-metodo-multiagente.md`. Se incluye porque casi todo el cuaderno lo produjo una flota de agentes bajo revisión humana, y eso condicionó qué defectos aparecieron y cuáles sobrevivieron meses: un lector que evalúe las cifras necesita saberlo, igual que necesita saber el modo de potencia.

Se cuenta en las dos direcciones o no se cuenta. Encontró lo que el trabajo en solitario no había encontrado (la auditoría de máquina sobre 76 campañas, los cuatro números mal del `README.md`, el fallo de re-emparejamiento de ByteTrack). Y produjo defectos con la misma firma —confiados, precisos y falsos— entre ellos la cámara apuntando al cielo y un `b=39, c=7` salido de adivinar un esquema JSON. La conclusión operativa es que **la verificación tiene que ser un artefacto ejecutable y no un párrafo**: la regla «no te fíes de tu primera lectura» estaba escrita, en mayúsculas, en el mismo fichero que contenía tres citas erróneas.

Amenaza a la validez que la propia sección declara: no hay grupo de control, luego ninguna afirmación causal sobre el método es defendible. Solo el registro de incidentes, y cada uno resuelve a un *commit*.

4.5 Qué le hizo el re-análisis al cuaderno

Este es el material del Cap. 9 y conviene anticiparlo aquí, porque **el marco no se escribió para adornar resultados sino porque cambió varios.**

Categoría	N	Qué significa
Significativas tras Holm	6	Se pueden defender como efectos
Sin prueba posible (0 discordantes o solo agregados)	30	No hubo contraste, en ninguna dirección
Diseño incapaz de alcanzar alfa	35	Ningún resultado posible habría bastado
Sin datos crudos	3	En cola de re-ejecución, no se defienden

Tabla 4.1: Resultado global del re-análisis retroactivo de las 65 afirmaciones con puerta

Las seis que sobreviven son la catástrofe de fidelidad de la Parte I, la escalera de resolución y la puerta LoRA de la Parte II, la palanca ROI de la Parte III, la generalización del arranque en caliente (P5.2a) y la recalibración del banco (P5.12). **La contribución central del TFM está entre ellas**, que es lo que hacía falta comprobar.

Y tres correcciones que el re-análisis obliga a llevar al texto:

- **Swin2SR no pierde en precisión** (ver Cap. 5). El descarte es por latencia.
- **La catástrofe de la Parte I es la exportación, no la cuantización.** F16 contra Q8_0 da $b = 17$, $c = 10$, $p = 0,25$: los 7 pp que el cuaderno atribuye al cuantizado no se distinguen del ruido. La brecha HF contra GGUF, en cambio, es significativa bajo **cualquier** emparejamiento compatible con los marginales (peor caso $p = 1,3e-4$), que es la forma correcta de defenderla cuando el brazo HF no dejó registro por elemento.
- **El arrastre a 768 no pierde precisión medible frente a 1024.** Por pista, 1024 gana 55 veces y 768 gana 31, $p = 0,013$ — pero las 186 pistas salen de 93 secuencias, y sobre esa unidad independiente la prueba de signos da $b = 28$, $c = 16$, **$p = 0,096$** , que Holm deja en 1. Un borrador anterior de este esquema afirmaba lo contrario (**corregido el 2026-07-21**, R-7): fue el propio re-análisis el que lo desmintió, porque las salvedades del registro se habían escrito antes de la deflación de R-4. La adopción de 768 nunca

fue una afirmación de igualdad: era una cota de tamaño de efecto más una restricción de FPS, y hay que redactarla así.

4.6 La topología real del banco

Esto es lo que más se malinterpreta al leer el cuaderno. En casi todas las partes, **la Jetson ejecutó solo el VLM**, servido por SSH con un PNG en base64 cruzando el cable por llamada; el arrastre con SAM2, el replay de vídeo y el scoring corrieron en una RTX 3090 de sobremesa. El capítulo debe presentar el diagrama del banco antes de dar una sola cifra, porque de otro modo el lector supone un sistema embarcado que nunca se midió como tal.

5. Capítulo 4 — Grounding de un solo frame

Cubre Parte I (exploratoria, congelada) y Parte II (reconstrucción principiada).

5.1 Qué se cuenta

La Parte I se cuenta **como fracaso metodológico**, no como resultado. Produjo una catástrofe de fidelidad: lo medido en el banco no era lo que ocurría en el dispositivo. La Parte II existe porque esa lección obligó a reconstruir la evaluación desde cero con fases con puerta y con manifiestos por ejecución (SHA de git, hash del lockfile, hash del dataset) que la Parte I no tiene.

Sin ese arco, la Parte II parece burocracia. Con él, es la respuesta a un fallo concreto: "cinco copias divergieron en silencio".

5.2 Cifras que se citan, con su matiz

- Espina dorsal: Qwen2-VL-2B [1], cuantizado a Q8_0 con llama.cpp [2].
- Fase 3, LoRA [3]: **59,5 %** IoU@0,25 sobre RefDrone [4] a $n = 439$. No citar el 65,0 % en bucle ($n = 200$) como titular.
- Fase 4: 59,5 % (HF) a 62,2 % (F16) a **62,6 %** (Q8_0 en la Jetson).

5.3 La corrección de signo más importante del documento

El cuaderno etiqueta ese último salto como "-2,7 pp" y lo repite en cuatro sitios. **Es una convención de magnitud de brecha, no una pérdida.** Las cifras suben: el artefacto cuantizado puntúa por encima de la referencia HF. La lectura honesta, que el propio README de la campaña ya recoge, es que una inversión de ~3 pp sobre $n = 439$ está dentro del ruido de muestreo y significa **"sin pérdida medible por el runtime"** — nunca "la cuantización mejora el modelo". Escribirlo como pérdida sería un error; escribirlo como mejora sería peor.

Lo mismo pasa con la brecha original de la Parte I: hay **dos medidas del mismo fenómeno y no coinciden** (85,0 a 62,0 a 55,0, es decir -23 pp; frente a la re-medida de la Fase 0b sobre el mismo checkpoint, 85,0 a 69,0 a 67,0, -16 pp). La diferencia se atribuye a decodificación voraz frente a muestreada y a $n = 100$ frente a $n = 200$. El TFM debe dar el par y la explicación, no elegir el número más dramático.

5.4 Advertencia obligatoria sobre RefDrone

El 62,6 % **no es comparable con la tabla de RefDrone**. El benchmark publicado mide **F1 multi-objetivo a IoU $\geq 0,5$** (una expresión puede mapear de 0 a 242 cajas); el estado del arte allí es 34,44 F1 y el techo humano 58,14. Lo que aquí se mide es **una caja, IoU@0,25**, sobre el 30,9 % de las captions de validación que tienen exactamente una caja real (n = 439 de 1.421). Se descartan precisamente los casos multi-objetivo y los negativos, que son para lo que RefDrone fue construido.

Es un protocolo distinto y más fácil. Poner el 62,6 % al lado del 34,44 sin esa frase sería una tergiversación.

5.5 Licencias

Las anotaciones de RefDrone son CC BY 4.0 pero reutilizan imagen de VisDrone2019-DET bajo CC BY-NC-SA 3.0, de uso académico. Vale para un TFM y **hay que declararlo**: la etiqueta permisiva de aguas abajo no anula la cadena de aguas arriba.

5.6 Figuras

Ninguna existe. **Todas por generar** desde `runs/*/results.json`.

- POR GENERAR: barras banco-vs-dispositivo con las dos medidas discrepantes de la brecha de la Parte I, que es la figura que justifica la existencia de la Parte II.
- POR GENERAR: rejilla cualitativa de aciertos y fallos de grounding sobre imagen aérea.
- POR GENERAR: bake-off de backbone [5, 6, 7, 8, 9]. Cuidado: los brazos **no comparten backend ni n** (A y C en HF a n = 200; el titular y B en Jetson Q8_0 a n = 439; D cancelado sin ejecutar). Sostiene "ningún brazo desplazó al titular", no una clasificación.

6. Capítulo 5 — Permanencia de objeto

Parte III (T0-T4) más la exportación E1.

6.1 Qué se cuenta

Un grounding por frame no es seguimiento. Aquí entra el arrastre temporal: SAM2 [10] mantiene la máscara entre anclajes y el VLM solo se invoca para re-anclar.

6.2 La palanca ROI, dicha con precisión

Es el mejor resultado del proyecto y el más fácil de exagerar.

- **Precisión:** 85,2 % IoU@0,25 — medido con pesos **HF bf16 en la RTX 3090**, no en la Jetson y no a Q8_0. La confirmación en dispositivo estaba pre-registrada como "el único pendiente antes de cambiar el valor por defecto" y **nunca se cerró**.
- **Delta:** el "+22,6 pp" compara 85,2 % (HF bf16, 3090) contra 62,6 % (Jetson Q8_0, y además contra un checkpoint ya sustituido). El control mismo-backend medido en el mismo barrido es el brazo HF a frame completo, 64,0 %, lo que da un delta comparable de **+21,2 pp**. Ese es el número defendible.
- **Latencia:** 2,7x de prefill (3691 ms a 1374 ms) frente a frame completo a 1024. La mitad de latencia sí es una medida Jetson Q8_0.
- **Cadencia:** el anclaje a ~2,0 s no es una mejora de 3x. Frente a la constante original de frame completo a 512 (2,26 s) es marginal, porque un recorte de 512x512 lleva píxeles parecidos. La mejora real es contra la ruta desplegada a 1024: **4,81 s a 2,02 s, 2,4x**, extremo a extremo.

Y la referencia desplegada ya no es 62,6 %: el checkpoint terse mide **63,1 %** a frame completo en la Jetson. Cualquier "+22,6 pp sobre el modelo desplegado" es contra un modelo que ya no se despliega.

6.3 Cifras de arrastre y de exportación

- Precisión del arrastre: 0,849 a `image_size` 1024 y 0,830 a 768, sobre 186 pistas de AerialMind — **en la 3090**. En la Jetson solo se midieron FPS y RAM. Sembrado además desde una caja de verdad-terreno del primer frame: siembra oráculo, no lenguaje.
- E1, encoder de SAM2 a TensorRT fp16 [11]: **4,89 a 6,15 FPS en banco solo**. En el bucle integrado el mismo encoder da **5,0 FPS**, con $n = 1$, y despeja la puerta de ≥ 5

exactamente. El bucle pierde ~1,15 FPS en codificar/decodificar JPEG y en el túnel SSH.

- Antes de E1 la tasa co-residente era **4,1 FPS frente a la puerta de 5**: un fallo marginal registrado como tal.

6.4 Dos formulaciones que hay que evitar

- **"Se rechazó EdgeTAM frente a SAM2"** es falso. EdgeTAM era una alternativa condicional pre-registrada a la que nunca se llegó, porque SAM2 + TensorRT despejó la puerta en el paso anterior. Nunca se midió, en ningún hardware. Se escribe "no hizo falta el plan B", jamás "ganó la comparación".
- **"7,6 Hz de tasa del sistema"** está inflado por fases ciegas. La tasa del sistema es la de la fase de arrastre.

6.5 La palanca de super-resolución, descartada

Swin2SR [12] sobre el recorte ROI **no compra nada medible** por +1331 ms. Y aquí el re-análisis **corrige la nota de laboratorio**: la campaña lo registró como "pierde también en IoU", pero sobre los datos por elemento ($n = 429$) ningún brazo se separa de otro. Frente a LANCZOS, $b = 21$ y $c = 14$, **$p = 0,31$** ; frente a bicúbico, $b = 22$ y $c = 12$, **$p = 0,12$** ; y el propio bicúbico contra el nativo da $p = 0,26$. El descarte es correcto y se sostiene **por latencia**, que es determinista y enorme; escribir que Swin2SR "pierde en precisión" sería afirmar más de lo que hay. Con dos matices más: la prueba usó un recorte oráculo de 400x400 centrado en la verdad-terreno (mide el techo que la SR podría ofrecer, no el extremo a extremo) y $n = 429$, habiendo descartado 10 muestras por una razón no aleatoria — los objetos más grandes no caben en 400 px. La literatura de SR en teledetección [13, 14] no transfiere a este recorte.

6.6 Figuras

Parte III tampoco tiene `proof/`. Existen dos GIF sueltos (`permanence.gif` , `closedloop.gif`) y tres clips del demo, todos versionados y reutilizables.

- POR GENERAR y **prioritaria**: la rejilla ROI ($M \times$ resolución de salida) con los dos ejes, precisión y prefill. Es el mejor resultado del proyecto y hoy no tiene imagen.
- Reutilizable: `experiments/2026-06-24-t2-permanence/permanence.gif` y `.../t3-closed-loop/closedloop.gif`.

7. Capítulo 6 — El arco de la latencia de adquisición

Parte IV, E2 a E23. **El capítulo pivote.**

7.1 Qué se cuenta

Con el sistema integrado sobre vídeo real de UAV123 [15] aparece un fallo que ningún experimento por componentes veía: la adquisición en frío tarda ~4,85 s y sobre un objetivo en movimiento **la caja se entrega obsoleta**. El sistema no falla al encontrar el objeto; falla al encontrarlo donde ya no está.

Luego se cuentan los intentos de arreglarlo por la vía directa:

- **E20**, pista de recorte tomada de la frase del operador: 1,85 s, la única adquisición sub-2 s que funciona. Voltea 3 de 6.
- **E21** (segunda pasada del VLM), **E22** (prior en CPU) y **E23** (celda más ancha): los tres fallan al automatizar la pista.

7.2 La inferencia que arrastra el resto del documento

Cuatro intentos independientes, tres fracasos y un éxito que **no es autónomo**. La conclusión no es "hay que optimizar más", es que el problema está mal planteado: si la orden llega en t y la respuesta en $t + 4,85$, ninguna optimización sobrevive a un objetivo que se mueve. Hay que cambiar **cuándo empieza** el cómputo, no cuánto dura.

Eso es la Parte V.

7.3 Advertencias que acompañan a cada cifra de este capítulo

- Los ~4,85 s **incluyen cable**: se midieron con un PNG sin pérdidas en base64 cruzando un túnel SSH desde la estación de trabajo hasta la Jetson, sobrecarga que un despliegue con cámara a bordo no pagaría. El instrumento `transfer_ms` construido para exactamente esta pregunta nunca se ejecutó sobre la cifra titular de E18. Quedan además ~450 ms sin atribuir entre el `t_lock` de 4,85 s y la mediana instrumentada de 4400 ms.
- El arco completo E18-E23 es **$n = 6$ clips, todas coches, de un solo dataset**, con captions congeladas escritas a mano, $n = 2$ repeticiones por celda, **solo percepción** — sin actuación ni vehículo en el lazo — y con el arrastre en la 3090 limitado a 6,15 Hz como

sustituto del Orin. Los veredictos son 1/6, 2/6 y 3/6: diferencias de una sola clip, sin prueba estadística posible.

- **E20 no es autónomo:** exige que el operador dé una frase espacial correcta, y una pista **equivocada es peor que ninguna** (cobertura 0,000, plantilla de máscara envenenada, cero recuperación). El encuadre honesto es "un rodeo con humano en el lazo que resistió tres intentos de automatización", no "una solución".
- El techo de seguimiento de 2,5 m/s (3,0 con chase-hold) se midió en SITL contra un **renderizador nadir sintético** — una textura plana con un rover dibujado a 640x480 — no sobre imagen real, con $n = 2$ o 3 por peldaño. El propio repositorio contiene la refutación: E11 dio PASS a 3,5 m/s con 2/2 y **E12 lo revirtió** a $n = 3$.
- **E14 no replica.** Su "3/3, agujero de identidad cerrado" se convierte en **6/8, CUALIFICADO y explícitamente no fiable** en la replicación E16. El matiz atenuante, que merece decirse: 0 de 8 violaron la identidad, luego los dos fallos son de temporización aguas arriba de la puerta, no de la puerta.
- Los números de estrés de E15 están **registrados pero no reclamados:** falló su guarda de línea base, así que el veredicto es NO MEDIBLE.

7.4 Figuras

Casi todo son clips `.mp4`, que es lo correcto cuando el comportamiento es el argumento. Solo hay dos figuras (E22 y E23).

- Reutilizable, **la figura titular de la Parte IV:**
`experiments/2026-07-03-real-video-replay/proof/car9_A_vs_B.mp4`, la adquisición real contra su control.
- Reutilizable, **la prueba de fragilidad de E20:** `.../2026-07-04-prompt-scoped-acquire/proof/wrong_car10_r1_wrongprobe.mp4`, donde una pista errónea hace que el VLM alucine.
- POR GENERAR: no existe ninguna figura cuantitativa del arco de latencias (4,85 a 1,85 a 2,73 a 2,80 s) ni de la escalera de velocidades. Hay que hacerlas.

8. Capítulo 7 — Grounding anticipatorio

Parte V, P5.1 a P5.20. El capítulo más largo y el que contiene la contribución.

8.1 Estructura interna propuesta

No se narran veinte experimentos en orden. Se narran cuatro hilos:

- **El arranque en caliente funciona.** P5.1 (5/6 frente a 1/6 en frío) y P5.2 (21/25 frente a 5/25 sobre 25 clips y 5 categorías).
- **Seleccionar entre candidatos es donde duele.** P5.3, P5.4, P5.5, P5.10, P5.13 y P5.17: seis intentos sin separación o sin robustez, agrupados por causa y no por número.
- **Lo que sí lo desbloqueó.** P5.14 cambia el **contrato de entrega** — entregar la pista ya arrastrada en lugar de re-ancorar al recibir la orden. P5.16 quita el oráculo de la semilla y cuesta una celda de doce.
- **Dónde está el límite.** P5.15 (el arrastre aguanta 24 s de espera, 24/25: **el arrastre no es la parte frágil**), P5.18 (a $n = 26$ el SWAP reforzado cae a 17/26), P5.19 (sube a 20/26) y P5.20 (un SAM2 mayor no recupera ninguna celda: palanca muerta).

8.2 El estadístico, ya calculado

Cifras generadas por `thesis/run_stats.py` desde `thesis/claims.json`, no estimadas. McNemar **exacto bilateral**, que es el que se reporta en todo el documento; el unilateral es la mitad y no se usa para decidir nada.

Resultado	Discordancia	McNemar exacto	Lectura
P5.1 WARM 5/6 vs COLD 1/6	b = 2, c = 0	p = 0,5	No significativo por sí solo
P5.2a WARM 21/25 vs COLD 5/25	b = 15, c = 0	p = 6,10e-5	El ancla estadística de la parte; sobrevive a Holm
P5.10 DD 24/24 vs RG 24/24	b = 0, c = 0	indefinido	No hubo prueba, no hubo empate demostrado
P5.13 y P5.17	b = 0, c = 0	indefinido	La única celda discordante se colapsa al agrupar por clip
P5.19 SWAP 20/26 vs P5.18 17/26	b = 2, c = 0	p = 0,5	Compatible con el azar

Tabla 8.1: Inferencia post-hoc sobre los resultados con puerta de la Parte V, generada desde los volcados por elemento

Todos los b/c de esta tabla son **posteriores a la deflación** por unidad independiente (R-4): las cifras sin deflactar, mayores, están en `thesis/stats-report.md` entre corchetes en cada fila.

La fila de P5.10 estaba mal agrupada en el borrador anterior de este esquema, y la distinción importa: P5.13 y P5.17 **corrieron** una prueba que no separó nada, mientras que P5.10, con cero pares discordantes, **no corrió ninguna**. Reportar p = 1,0 allí habría sido afirmar equivalencia demostrada.

De aquí salen dos consecuencias narrativas:

- **P5.1 no puede ser el titular.** Es defendible solo porque P5.2 lo replica a n = 25 y cinco categorías. El titular es P5.2.
- **Los tres empates de simulación no demuestran equivalencia.** Con una sola celda discordante, McNemar da p = 0,5, que es literalmente ninguna información. La afirmación correcta es "este banco no pudo discriminar los contratos", que es lo que dice el repositorio.

8.3 Advertencia obligatoria sobre P5.19

P5.19 pasa su listón **exactamente**, 20/26 contra un listón de 20. Con tres pares discordantes en una sola dirección, McNemar exacto bilateral da p = 0,25, y el intervalo de Wilson al 95 % es [0,579, 0,890], que **cruza el listón de 0,769**. La mejora es compatible con el azar al

tamaño de muestra usado: harían falta **seis** pares discordantes en la misma dirección para alcanzar alfa a $n = 26$, y hubo tres.

Y las 26 celdas no son 26 observaciones independientes: salen de **13 videoclips**. Deflactada a esa unidad, la discordancia baja a $b = 2$, $c = 0$ y **$p = 0,5$** , y el listón pre-registrado de 20/26 se convierte en 10/13 sobre una línea base de 8/13. El valor p no empeora de significativo a no significativo — nunca fue significativo. Lo que la deflación borra es el margen justo en la barra, que era precisamente el argumento que el resultado hacía.

Se presenta como una señal a replicar, no como significativa. Y se argumenta **por replicación, no por p** : que P5.20 reprodujera P5.19 celda por celda, sin un solo cambio, es mejor evidencia de que el efecto es real que cualquier contraste a este n .

Además, la precisión de la entrega con gracia es **2/4**, y cuando falla **entrega una caja ajustada y confiada sobre el objeto equivocado** (IoU 0,679 y 0,865) en vez de abstenerse. En despliegue no hay verdad-terreno que lo detecte: es un fallo silencioso, y es el peor modo posible para algo que pilota. Falsificó además su propia predicción de "suelo de regresión ~ 0 ".

8.4 Matices que viajan con los números

- **acquire_s = 0,00 s del contrato de entrega directa es definicional, no medido.** No hay paso de adquisición que cronometrar. Es válido como enunciado del contrato, pero decir "hicimos la adquisición 4,5 s más rápida" sin añadir que el coste se trasladó a la tubería que corre continuamente durante la espera es engañoso.
- **De las cuatro pérdidas de P5.2, dos son degeneradas:** el objetivo no está en el frame de entrega, así que el oráculo también falla. El repositorio reporta correctamente $21/23 = 91\%$ sobre el conjunto no degenerado, y ese calificador debe viajar con la cifra.
- **El rho = -0,06 del barrido de velocidad no tiene p-valor ni intervalo.** Sostiene "no se observa dependencia de la velocidad", no "es plano".
- **P5.16 no es un resultado vigente.** Su 4/5 fue derribado por P5.18 con el mismo arnés byte a byte: la tasa real es $17/26 = 0,65$. Se presenta como un paso cuyos números no sobrevivieron.
- **El arrastre nunca corrió en la Jetson en toda la Parte V.** El presupuesto de 6,15 Hz es además el banco solo de E1; el integrado da 5,0 Hz, luego el limitador es $\sim 23\%$ optimista respecto al sistema desplegado.

8.5 El desvío de simulación

P5.7 a P5.13 y P5.17 construyen un banco de escenas sintéticas en Gazebo [16] para conseguir los cruces y oclusiones que UAV123 no da. Terminan en un **no**: el VLM ancla 56 de 56 renders limpios, los contratos empatan siempre y el banco no discrimina.

La conclusión útil es metodológica: la ventaja del contrato bueno vive en la **fragilidad ante imagen real**, y un render limpio la borra. Dos páginas, no diez. Merece mención el defecto que P5.13 encontró mirando: el coche blanco era el más cercano en 0 de 300 frames de todas las clips — orden de profundidad constante, y ninguna puerta lo cubría.

8.6 Figuras

Es la parte mejor documentada: `proof/` existe en todas las campañas.

- Reutilizable: `.../warm-start-generalization/proof/generalization_grid.png` (P5.2a, el titular) y `gap_vs_speed.png` (P5.2b, la figura que refuta la explicación intuitiva del propio resultado).
- Reutilizable: `.../warm-start-acquire/proof/car10_warm_vs_cold.mp4`, el clip de la caja obsoleta a 135 frames.
- Reutilizable: `.../select-generalization/proof/car7_460_SWAP_MC_driftNOMATCH.mp4`, la deriva de arrastre que es el bloqueo residual.
- POR GENERAR: la trayectoria de la afirmación de selección de P5.14 a P5.20 **con intervalos de Wilson**, que es la figura que obliga a poner P5.18.

9. Capítulo 8 — Hacia el lazo cerrado

Parte VI, P6.0 y P6.1. Corto y **honesto sobre lo que aún no demuestra**.

9.1 Qué se cuenta

Todas las cifras de la Parte V se midieron sobre vídeo grabado que el sistema no podía influir. No había vehículo en el lazo. La Parte VI pone la selección delante de un copter volando — ArduCopter SITL [17] como física, CARLA 0.9.16 [18] como renderizador esclavo de pose — para que los píxeles pasen a ser consecuencia de la propia salida de control. Es la etapa SIL del marco de [19].

- **P6.0**, puerta de capacidad: PASS. Encontró un fallo de re-emparejamiento en ByteTrack [20] que convertía el «coasting de Kalman» en un mantenedor de orden cero. Error de píxel 64,7 a 36,0.
- **P6.1**, cambio de renderizador: YES. 48,1 Hz —tasa del bucle de renderizado, sin percepción dentro de la ventana— con 40 vehículos autónomos siguiendo un vuelo GUIDED real (0 a 84,4 m a 60 m sobre el terreno), con la pila de control intacta.
- **Banco GT de CARLA** (2026-07-21): 25 clips, 30.000 frames con verdad-terreno por actor proyectada, puertas G-A PASS / G-B CERRADA / G-C PASS.

9.2 Tres cifras de este capítulo que NO deben citarse

Es el capítulo con más métricas vacuas del proyecto. La auditoría R-10 (2026-07-21) las revisó una por una contra los artefactos y encontró que **la razón que el cuaderno les atribuía era la equivocada en dos de las tres**. Esa corrección es en sí misma contenido: una métrica se puede desautorizar por el motivo incorrecto y seguir pareciendo bien auditada.

- **slave_err = 0,000 m**. La cámara es un `sensor.camera.rgb` sin `attach_to`: un actor cinemático sin dinámica, luego `get_transform()` devuelve exactamente lo que `set_transform()` le acaba de pasar. Tres matices que R-10 añade. Primero, **el 0,000 no está en el fichero**: el artefacto guarda `1,815e-06`, y el cero es el formato de impresión `:.3f`, de modo que quien busque la cifra publicada dentro del `results.json` no la encontrará. Segundo, la métrica sólo lee `.location`, así que **no compara la rotación** — y el guiñada del `pose_track` tiene **un único valor, 0,0, en los 600 ticks**, porque el sondeo `ATTITUDE` nunca entregó nada: el renderizador estaba esclavizado **en posición**, no en pose, y nadie lo vio precisamente porque la métrica es

ciega a la rotación. Tercero, **sí existe un sustituto no vacuo y se calcula del artefacto ya comprometido**: los ticks que reutilizan una pose MAVLink caducada son el 60,4 %, el hueco máximo entre muestras frescas es 0,547 s y a 7,21 m/s eso son ~3,9 m de retraso de cámara en el peor caso. Es seis órdenes de magnitud mayor que la cifra publicada.

- **«0 pérdidas de pista» en P6.0.** El cuaderno lo atribuía al fallo de ByteTrack; **es falso**. El contador sólo se incrementa cuando el rastreador devuelve una lista vacía, lo que exige `MAX_LOST_FRAMES = 30` fotogramas a 20 Hz, es decir **1,5 s sin ninguna detección**, y esa rama era igual de alcanzable antes y después del arreglo. Lo que hace inútil el 0 es que la inyección a 1 Hz nunca produjo una sequía de 1,5 s, y la única ejecución diseñada para forzarla (`GAP_INJECT_RUN = 3`) nunca se lanzó. La prueba está en la propia tabla: la ejecución rota (40 IDs, 64,7 px) y la arreglada (7 IDs, 36,0 px) **reportan ambas 0**. Enunciado correcto: *0 pérdidas de pista significa que el suministro de detecciones nunca se cortó; no es evidencia de que el lazo mantuviera el objetivo*.
- **Los 48,1 Hz como tasa disponible para trabajo real.** Se midieron a 640x480, 40 vehículos, sin proyección de verdad-terreno ni escritura JPEG y **sin límite de potencia**, y sobre todo **sin percepción dentro de la ventana de medida**: ni VLM, ni SAM2, ni ByteTrack, ni PID. El banco GT, en el mismo servidor y mapa pero con 80 vehículos, proyección por actor, escritura JPEG y la GPU limitada a 200 W, sostiene **15,88 Hz**. No son comparables. Y el «2,4x la tasa de control» queda **retirado**: la ejecución fue en modo síncrono, 600 ticks de 0,05 s de tiempo simulado entregados en 12,46 s de reloj de pared, así que el simulador corrió 2,41x más rápido que el tiempo real mientras SITL, la fuente de pose, iba a reloj de pared. `48,08 / 19,93` y `30 / 12,46` son **el mismo 2,41**: la supuesta holgura era el desfase de reloj reenunciado.

9.3 Síncrono contra asíncrono: la distinción que hay que declarar siempre

El banco GT corre en modo **síncrono** y el banco de vuelo en **asíncrono**. Coexisten por decisión deliberada y **cada resultado debe nombrar cuál lo produjo**, porque en modo síncrono una adquisición de 4,5 s cuesta **cero segundos de simulación**: el retardo de entrega que las Partes IV y V existen para medir sencillamente deja de existir. Mezclar ambos conjuntos de cifras invalidaría justamente lo que el TFM defiende.

Corolario: el banco GT es determinista, pero **la Parte VI de vuelo pierde el determinismo** que toda la Parte V tenía. SITL corre en tiempo real y no se puede avanzar frame a frame, así que los ensayos de vuelo son estocásticos; la mitigación es estadística (semilla de escena + $n \geq 25$ + reportar la banda de ruido de planificación), no exacta.

9.4 Lo que este capítulo NO afirma

- **P6.2 no se ha ejecutado.** La Parte VI ha producido una puerta de capacidad, un cambio de renderizador y un banco instrumentado: infraestructura habilitante, no la afirmación. Sus tres premisas — que el arrastre sobrevive a la ego-motion que el propio sistema induce, que el presupuesto de latencia sobrevive al reloj de pared, y que el contrato de selección es entregable a un controlador — siguen **sin falsar, porque ningún experimento ha podido falsarlas todavía.**
- **G6 no se ha ejecutado,** luego el renderizador CARLA **no está validado para la etapa de grounding.** Su predicción (peor que los 56/56 de Gazebo, mejor que UAV123) está sin probar.
- **Ninguna campaña de la Parte VI tuvo la Jetson en el lazo.** Las detecciones de P6.0 se inyectan geométricamente; el servidor de CARLA exige una GPU de sobremesa y no corre en el Orin. Ninguna cifra de la Parte VI es una cifra de despliegue.
- **Ninguna taxonomía de identidad o de deriva salida de este banco es fiable todavía.** El emparejador de actores de `runners/carla_debug_ui.py` tiene seis modos de fallo silencioso verificados, entre ellos una superposición normalizada por la caja menor que da 1,0 a una máscara sobre un retrovisor.
- **Las tres "regiones" de `track_gain`** que una nota anterior de la campaña describía están **retiradas** a $n = 25$: solo la ganancia 1,0 es un régimen limpio, y las otras dos se solapan.
- **CARLA no es comparable con el banco de Gazebo** de la Parte V. Los 56/56 de P5.17 son un contraste, no una línea base. Fue un coste aceptado y registrado del cambio.
- **Ni tiempo atmosférico ni hora del día** se ejercitaron: todos los frames son mediodía despejado, y la cámara es **nadir fija**, mientras que el vídeo real de UAV y el banco de la Parte V son **oblicuos**. Una afirmación de fidelidad que solo vale al mediodía y desde arriba es una afirmación estrecha.

9.5 Dos limitaciones del artefacto, para quien lo reutilice

- Los identificadores de actor del `gt.jsonl` los asigna el servidor y **CARLA no los reproduce entre cargas de mundo.** Valen dentro de una clip y no pueden usarse para emparejar identidades entre ejecuciones, que es exactamente lo que querría un A/B pareado sobre la misma semilla. La clave estable por índice de spawn exige una recaptura de 36,5 min y no se ha añadido.
- Sobreviven **19 cajas degeneradas de anchura cero** en 897.864 (2,1e-05), lascas de borde de frame serializadas a dos decimales. Un consumidor que calcule IoU divide por cero. El arreglo de serialización llegó después de la captura y el banco no se recapturó: hay que filtrarlas.

9.6 Dos fallos que merecen media página cada uno

Son aportación metodológica, no anécdota:

- **La cámara apuntaba al cielo.** Un pitch de $+\pi/2$ en Gazebo es **abajo**, no arriba. Durante toda una fase el log salía limpio, se escribían ficheros bien formados, y la conclusión asociada (RQ-S1.4) hubo que **retirarla**: se había medido a través de una imagen gris plana, 100 % de un solo color. Es el caso concreto que motivó la regla de verificación visual del proyecto. En trabajo de simulación, **un exit 0 no es evidencia sobre píxeles.**
- **La métrica vacua, y el diagnóstico vacuo de la métrica vacua.** «0 pérdidas de pista» no medía nada, y el cuaderno lo desautorizó por el motivo equivocado: culpó al fallo de ByteTrack cuando el contador exigía 1,5 s sin detección alguna, algo que el arnés nunca produjo ni antes ni después del arreglo. La lección de segundo orden es la útil: **desautorizar una métrica no es lo mismo que entenderla**, y una nota de «no citar esta cifra» puede envejecer tan mal como la cifra.

10. Capítulo 9 — Amenazas a la validez

Capítulo propio, no notas al pie. Estas son las que un tribunal encontraría.

10.1 "Todo corre en la placa" no es lo que se midió

El eslogan del proyecto dice que todo corre en el borde sin nube. La realidad: **el arrastre con SAM2 nunca se ejecutó en la Jetson en la Parte V**, y en las partes anteriores la precisión del arrastre se midió siempre en la 3090 mientras la placa aportaba solo FPS. La única medida co-residente integrada dio 4,1 FPS frente a su propia puerta de 5 antes de E1, y 5,0 FPS después — despejándola exactamente, con $n = 1$. La formulación del `README.md` era más fuerte que la evidencia; se corrigió el 2026-07-21 en `cd8cca6` (las tres frases «todo corre en la placa», el compuesto de +22,6 pp, la precisión de arrastre de 1024 px citada para un sistema que despliega 768 px, y el techo de seguimiento publicado como 3,0 m/s cuando 3,0 es el ajuste que falló).

La Parte VI **agrava** esto en lugar de resolverlo: ninguna de sus campañas tuvo la Jetson en el lazo, porque el servidor de CARLA exige una GPU de sobremesa. El arco de lazo cerrado se mide íntegramente en la 3090.

10.2 Composiciones entre máquinas

Varias tablas del cuaderno emparejan una precisión medida en la 3090 con unos FPS medidos en el Orin. Cada una de esas filas describe un sistema que nunca existió. El TFM debe etiquetar la máquina en cada celda o separar las tablas.

10.3 Tamaños de muestra e inferencia

Buena parte de las decisiones se tomaron con n de 2 a 6. El re-análisis del 2026-07-21 cuantifica el daño: de 65 afirmaciones con puerta, **33 salen de diseños que no podían alcanzar $\alpha = 0,05$ con ningún resultado posible** y solo **6 sobreviven a la corrección de Holm**. P5.18 ya lo había demostrado empíricamente: un 4/5 se convirtió en 17/26 al medirlo bien. E12 revirtió a E11 por la misma razón. El proyecto adoptó después una regla de $n \geq 25$ para todo brazo con puerta, que **post-data a las Partes I a IV completas**. Los resultados anteriores se presentan con su n visible y, donde importe, con su intervalo de Wilson.

La regla admite además una excepción declarada: P6.0 y P6.1 son puertas de capacidad con **$n = 1$** — dos vuelos únicos — y la exención se tomó a propósito, porque una puerta de

capacidad pregunta "existe la carretera", no "cuánto se tarda". P6.0 tampoco se pre-registró. Sirven para desbloquear P6.2 y **no soportan ninguna afirmación de rendimiento**.

10.4 El sim no es el mundo

Un PASS sobre render de Gazebo o CARLA no sostiene una afirmación sobre imagen real, y la Parte V lo demostró por la vía dura: el VLM acierta el 100 % de los renders limpios y de ahí no sale ninguna discriminación. El techo de seguimiento de la Parte IV se midió además contra una textura plana con un rover dibujado.

10.5 Resultados retirados

Los números de seguimiento en lazo cerrado de la Fase C de la Parte I están **retirados** (2026-07-20): se midieron a través de una cámara que apuntaba al cielo. Si el TFM los menciona es como caso de fallo metodológico, con las cifras tachadas y RQ-S1.4 declarada sin responder.

Retirada también la nota de la campaña del banco GT que describía **tres regímenes distintos de track_gain**: a $n = 25$ solo la ganancia 1,0 es un régimen limpio y los otros dos se solapan. `track_gain` no es un factor válido y no debe aparecer como eje de ninguna figura.

10.6 Irreproducibilidad de los pesos

El directorio de entrenamiento HF/safetensors fusionado se perdió y no sobrevive ningún adaptador LoRA. Los GGUF desplegados **no se pueden re-exportar**: un reentrenamiento daría un modelo distinto y rompería la comparabilidad celda a celda de las Partes II a V. Existe copia verificada por sha256 en `/home/gara/grounding-checkpoint-backup/`, pero es una copia en la misma máquina. Además, las ejecuciones de la Parte I **no llevan manifiesto** (SHA de git, hash del lockfile, hash del dataset), porque preceden a ese aparato: su garantía de reproducibilidad es estrictamente más débil, y arreglar eso fue un objetivo declarado de la Parte II.

11. Capítulo 10 — Conclusiones

- La contribución es el **replanteamiento**, no una arquitectura: cuando la orden es asíncrona, el instante en que empieza el cómputo importa más que su duración.
- Está acotada: se sostiene sobre cinco categorías de UAV123 con $p \sim 1,5e-5$ en el resultado de generalización, y el refinamiento de selección queda en una señal a replicar. El bloqueo residual es la deriva del arrastre entre objetos de la misma clase, no el grounding ni la entrega.
- Y está pendiente de la prueba que importa: nada se ha medido todavía con el vehículo cerrando su propio lazo.

12. Deuda de evidencia

Trabajo que hay que hacer **antes** de redactar, ordenado por lo que bloquea a más capítulos. No es redacción; es generar evidencia que no existe.

Partida	Bloquea	Esfuerzo
~~Calcular McNemar exacto y Wilson para todo brazo con puerta~~	Cap. 3, 6, 7, 9	HECHO 2026-07-21: <code>grounding/stats.py</code> , <code>thesis/claims.json</code> , <code>thesis/stats-report.md</code> , dos figuras
Re-ejecutar las 3 afirmaciones sin datos crudos (T2, T3, Fase C)	Cap. 5, 9	Ver <code>thesis/rerun-backlog.md</code>
Generar la figura de la rejilla ROI desde <code>sweep_summary.json</code>	Cap. 5	Bajo, y es el mejor resultado sin imagen
Generar las figuras de las Partes I-II (brecha de fidelidad, bake-off)	Cap. 4	Medio — no hay <code>proof/</code> , hay que reconstruir de logs
Generar la figura cuantitativa del arco de adquisición	Cap. 6	Medio
Justificar por escrito el umbral IoU@0,25 y reportar el IoU medio	Cap. 3, y todo lo demás	Bajo, pero es un flanco abierto
Verificar las entradas % VERIFICAR de <code>refs.bib</code>	Bibliografía	Bajo
~~Corregir el <code>README.md</code> raíz: "todo en la placa" y la puerta de FPS~~ HECHO <code>cd8cca6</code>	Cap. 9	—
Decidir si se cierra la confirmación en dispositivo del ROI a Q8_0	Cap. 5	Alto — es una ejecución, no una figura

Tabla 12.1: Deuda de evidencia previa a la redacción, con el capítulo que bloquea cada partida

Todo lo marcado como bajo desbloquea la mitad del documento y no exige GPU. La última partida es la única que obliga a volver a ejecutar algo, y es opcional: se puede escribir el Cap. 5 declarando el pendiente en lugar de cerrándolo.

13. Anexos previstos

Anexo	Contenido	Origen
A	Registro de afirmaciones con su prueba exacta, su máquina y sus matices	thesis/stats-report.md , thesis/claims.json
B	Registro de incidentes de desarrollo multiagente	thesis/02-metodo- multiagente.md
C	Cola de re-ejecuciones pendientes y qué afirmación desbloquea cada una	thesis/rerun-backlog.md

Tabla 13.1: Anexos previstos, con el fichero del repositorio que provee cada uno

14. Orden de recorte

Si el documento no cabe, se recorta en este orden y no en otro:

- El desvío de simulación baja de 2 páginas a un párrafo.
- La Parte I baja a media página de contexto.
- El bake-off de backbone pasa a apéndice.
- La subsección de método multiagente baja a un párrafo y el Anexo B se conserva entero.
- Las palancas descartadas del Cap. 5 pasan a una tabla única.

No se recorta: el Cap. 6 completo, la advertencia de P5.19, la corrección de signo del Cap. 4, ni ninguna amenaza del Cap. 9. Recortar una amenaza convierte una afirmación honesta en una afirmación falsa.

15. Siguiendo pasos

- Fijar fecha de entrega. Es la única variable que falta y ordena el resto.
- Atacar las partidas baratas de la deuda de evidencia, empezando por el script de estadística, que toca tres capítulos.
- Empezar a redactar por el Cap. 6, que es el pivote y fija el tono de los demás.

16. Referencias

- [1] Wang, P., Bai, S., Tan, S., Wang, S., Fan, Z., Bai, J., Chen, K., Liu, X., Wang, J., Ge, W., Fan, Y., Dang, K., Du, M., Ren, X., Men, R., Liu, D., Zhou, C., Zhou, J. y Lin, J. (2024). *Qwen2-VL: Enhancing Vision-Language Model's Perception of the World at Any Resolution*. arXiv preprint arXiv:2409.12191.
- [2] Gerganov, G. y contributors (2025). *llama.cpp*.
- [3] Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L. y Chen, W. (2022). *LoRA: Low-Rank Adaptation of Large Language Models*. International Conference on Learning Representations (ICLR).
- [4] Sun et al. (2025). *RefDrone: A Referring Expression Comprehension Dataset for Drone Scenes*.
- [5] OpenGVLab (2025). *InternVL3-2B*.
- [6] Qwen Team (2025). *Qwen2.5-VL-3B-Instruct*.
- [7] Google (2024). *PaliGemma 2 (3B, pt-448)*.
- [8] Microsoft (2024). *Florence-2-large*.
- [9] Hugging Face TB (2025). *SmolVLM2-500M-Video-Instruct*.
- [10] Ravi, N., Gabeur, V., Hu, Y., Hu, R., Ryali, C., Ma, T., Khedr, H., R\adle, R., Rolland, C., Gustafson, L., Mintun, E., Pan, J., Alwala, K. V., Carion, N., Wu, C., Girshick, R., Doll\ar, P. y Feichtenhofer, C. (2024). *SAM 2: Segment Anything in Images and Videos*. arXiv preprint arXiv:2408.00714.
- [11] NVIDIA (2025). *NVIDIA TensorRT*.
- [12] Conde, M. V., Choi, U., Burchi, M. y Timofte, R. (2022). *Swin2SR: SwinV2 Transformer for Compressed Image Super-Resolution and Restoration*. European Conference on Computer Vision (ECCV) Workshops.
- [13] (2025). *Advancing Image Super-resolution Techniques in Remote Sensing: A Comprehensive Survey*.
- [14] (2023). *EDiffSR: An Efficient Diffusion Probabilistic Model for Remote Sensing Image Super-Resolution*. arXiv preprint arXiv:2310.19288.

[15] Mueller, M., Smith, N. y Ghanem, B. (2016). *A Benchmark and Simulator for UAV Tracking*. European Conference on Computer Vision (ECCV).

[16] Open Robotics (2024). *Gazebo Sim 8.14.0 (Harmonic)*.

[17] ArduPilot Development Team (2025). *ArduPilot: ArduCopter SITL*.

[18] Dosovitskiy, A., Ros, G., Codevilla, F., L'opez, A. y Koltun, V. (2017). *CARLA: An Open Urban Driving Simulator*. Conference on Robot Learning (CoRL).

[19] Jiang, Y., Deng, Y., Schroder, S. y others (2025). *A Step-by-Step Guide to Creating a Robust Autonomous Drone Testing Pipeline*. arXiv preprint arXiv:2506.11400.

[20] Zhang, Y., Sun, P., Jiang, Y., Yu, D., Weng, F., Yuan, Z., Luo, P., Liu, W. y Wang, X. (2022). *ByteTrack: Multi-Object Tracking by Associating Every Detection Box*. European Conference on Computer Vision (ECCV).