

# **Metodo estadistico retroactivo**

*Como se decide que numeros del cuaderno de laboratorio son defendibles*

Marco de inferencia, 2026-07-21T13:10Z

*Realizado por Javier Francisco Dibo Gomez*

# Índice de contenidos

## **1. El problema que resuelve este documento**

1.1 Lo que este marco NO es

## **2. Tres modos de fallo que el marco vigila**

2.1 Diseno equivocado

2.2 Pseudo-replicacion

2.3 Disenos que nunca pudieron responder a su pregunta

## **3. Que prueba se aplica a que diseno**

3.1 Una trampa que el marco bloquea explicitamente

## **4. Empates y pruebas que no existen**

## **5. Cuando solo sobreviven los marginales**

## **6. Multiplicidad**

## **7. Estado de los datos: tres niveles**

## **8. Reproducir el analisis**

## Índice de tablas

**Tabla 2.1:** Cuantos pares discordantes en una sola direccion hacen falta para alcanzar  $\alpha = 0,05$  bilateral

**Tabla 3.1:** Regla de seleccion de prueba por diseno experimental

**Tabla 7.1:** Niveles de disponibilidad de datos y que permite afirmar cada uno

## Índice de bloques de código

**Bloque de código 2.1:** Correccion por efecto de diseno aplicada antes de cualquier intervalo o p-valor

**Bloque de código 8.1:** Comandos que regeneran el analisis completo desde el registro de afirmaciones

## 1. El problema que resuelve este documento

El proyecto se llevo como un cuaderno de laboratorio. Cada campana pre-registraba una puerta ("WSEL debe despejar 4/5"), ejecutaba el brazo, comparaba el recuento con la puerta a ojo y anotaba un YES o un NO. Como forma de dirigir un programa de investigacion es legitima y funciono: encontro la palanca del contrato de entrega, descarto la super-resolucion, mato la palanca de capacidad.

Como forma de defender una afirmacion en un TFM no vale. Una busqueda por `mcnemar | binomtest | scipy.stats | statsmodels | wilson | p-value` sobre el repositorio completo devolvia **cero ficheros** antes de este trabajo. Habia decisiones tomadas con  $n$  entre 2 y 6, sin intervalo de confianza, sin correccion por multiplicidad y sin una sola prueba de hipotesis.

Este documento define el marco con el que se re-analizan esas campanas. La implementacion esta en `grounding/stats.py` y su comportamiento esta fijado por `tests/test_stats.py`.

### 1.1 Lo que este marco NO es

No es un intento de convertir NOs en YESes. Anadir p-valores a posteriori es barato y casi siempre inutil. **La parte dificil, y la razon de que este modulo exista, es negarse a calcular los que enganarian.** Buena parte de lo que sigue son reglas de rechazo, no de calculo.

Tampoco es un re-analisis exploratorio. Las puertas ya estaban pre-registradas; lo que se anade es la incertidumbre que siempre debio acompanarlas, no una segunda oportunidad de encontrar un efecto.

## 2. Tres modos de fallo que el marco vigila

### 2.1 Diseno equivocado

McNemar exige que los **mismos elementos** se midan bajo ambos brazos. Aplicarlo a dos grupos independientes infla la significacion. La implementacion recibe unicamente los recuentos discordantes, de modo que un conjunto no pareado no puede llegar a la funcion por descuido; y `discordant_counts()` **descarta** los elementos que solo aparecen en un brazo, porque contar una ejecucion que fallo como un fracaso del brazo es como una caida se convierte en un resultado.

### 2.2 Pseudo-replicacion

"6 clips x 2 repeticiones" son 6 observaciones, no 12. Cinco celdas recortadas del mismo video no son cinco ensayos independientes. Miles de frames consecutivos de un unico vuelo son **un** vuelo: estan autocorrelacionados, y tratarlos como  $n = 30.000$  es la forma clasica de fabricar significacion a partir de un solo ensayo. Toda afirmacion lleva `n_effective` separado de `n_rows`, y el informe imprime los dos junto con la razon por la que difieren.

Separarlos no basta: hay que **usar** el que corresponde. Un intervalo calculado sobre `n_rows` y etiquetado con `n_effective` es peor que no dar intervalo, porque reclama una precision que nunca se compro. Ocurrio durante la propia redaccion de este marco — E17 imprimia `n = 1` junto a un IC de  $[0,000, 0,278]$  construido con 10 filas de un mismo fallo determinista — y de ahi sale `deflate_to_effective()`:

```
k, n = deflate_to_effective(k_observado, n_filas, n_effective)
```

*Bloque de código 2.1: Correccion por efecto de diseno aplicada antes de cualquier intervalo o p-valor*

Conserva la proporcion y sustituye el denominador por `n_effective`. Es una correccion por efecto de diseno con `deff = n_rows / n_effective`, y es deliberadamente tosca: **solo puede ensanchar el intervalo y debilitar el p-valor, nunca al reves**, de modo que no puede fabricar un resultado. Con la correccion aplicada, E17 pasa a  $[0,000, 0,793]$  sobre  $n = 1$ , que es lo que realmente sostiene una unica observacion. El informe marca cada caso afectado con `[deflated from k/n]` para que la deflacion sea visible y no un ajuste silencioso.

## 2.3 Disenos que nunca pudieron responder a su pregunta

Es el aporte principal del marco y el mas incomodo.

Una comparacion pareada de 5 elementos **no puede** alcanzar  $p < 0,05$  bilateral aunque los cinco pares volteen a favor: el suelo es  $p = 0,0625$ . Un  $n = 6$  llega justo, y solo si el resultado es perfecto (6 de 6 discordantes en la misma direccion,  $p = 0,031$ ).

| Pares (n) | Discordantes necesarios | Se puede alcanzar               |
|-----------|-------------------------|---------------------------------|
| 5         | —                       | <b>No, con ningun resultado</b> |
| 6         | 6 (todos)               | Solo si es perfecto             |
| 12        | 6                       | Si                              |
| 25 / 26   | 6                       | Si                              |
| 56        | 6                       | Si                              |

Tabla 2.1: Cuantos pares discordantes en una sola direccion hacen falta para alcanzar  $\alpha = 0,05$  bilateral

La consecuencia es dura y hay que decirla: **un NO salido de un diseno de  $n = 5$  no es evidencia de ausencia de efecto, es evidencia de ausencia de experimento.**

`min_discordant_for_significance()` lo calcula a partir de **n solo**, sin mirar el resultado, que es lo que lo hace legitimo a posteriori — a diferencia de la "potencia observada", que no es mas que el p-valor recalculado.

El mismo argumento vale para las puertas de una sola proporcion. Con  $n = 25$ , una puerta pre-registrada del **90 %** es inalcanzable en terminos estadisticos: un 25/25 perfecto da  $p = 0,9^{25} = 0,072$ . Una puerta asi solo puede despejarse descriptivamente.

### 3. Que prueba se aplica a que diseno

La eleccion la fija el **diseno**, nunca el p-valor que sale.

| Diseno                                               | Prueba                                            | Por que esta y no otra                                                                                            |
|------------------------------------------------------|---------------------------------------------------|-------------------------------------------------------------------------------------------------------------------|
| Binario pareado<br>(mismos clips, dos brazos)        | McNemar exacto                                    | Exacto y no ji-cuadrado: con $b + c \leq 5$ , que es lo habitual aqui, la aproximacion no vale                    |
| Binario de un brazo<br>contra una puerta             | Binomial exacta +<br>intervalo de Wilson          | La puerta es una probabilidad, no un recuento                                                                     |
| Binario no pareado                                   | Fisher exacta                                     | Grupos independientes                                                                                             |
| Continuo pareado<br>(latencias, IoU, error de pixel) | Wilcoxon de rangos<br>con signo + IC<br>bootstrap | Las latencias tienen cola derecha y $n$ es pequeno: la normalidad de una $t$ haria un trabajo que no se ha ganado |
| Sin hipotesis pre-registrada                         | Solo intervalo de Wilson                          | Descriptivo, y etiquetado como tal                                                                                |

Tabla 3.1: Regla de seleccion de prueba por diseno experimental

Todo exacto. Ninguna aproximacion normal: con estos  $n$ , ni la McNemar ji-cuadrado ni el intervalo de Wald serian correctos, y las versiones exactas no cuestan nada. Wald ademas falla justo donde vive este repositorio — en 24/25 da un limite superior por encima de 1, y en 0/6 colapsa a  $[0, 0]$ , afirmando certeza absoluta a partir de seis observaciones.

#### 3.1 Una trampa que el marco bloquea explicitamente

Sobre las cifras de P5.2 la prueba **no pareada** de Fisher da un **p menor** ( $1,2e-05$ ) que la McNemar pareada ( $3,1e-05$ ), porque McNemar descarta los 9 clips concordantes y saca toda su potencia de los 16 discordantes. Es tentador reportar Fisher.

Seria p-hacking por seleccion de prueba. Los 25 clips se midieron bajo ambos brazos, luego las observaciones estan pareadas y la prueba se deduce del diseno. `tests/test_stats.py` fija esta relacion con una asercion para que una sesion posterior no pueda cambiar en silencio al p-valor mas bonito y llamarlo mejora.

## 4. Empates y pruebas que no existen

Tres campanas de simulacion terminaron en empate casi perfecto (24/24 contra 24/24, 24/24 contra 23/24, 56/56 contra 55/56). Devolver  $p = 1,0$  en el caso del empate exacto se leeria como "probado, brazos equivalentes". No lo es: son **0 pares discordantes**, es decir, ausencia de prueba en cualquier direccion. `mcnemar(0, 0)` devuelve `NaN` a proposito y el informe lo imprime como `undefined`.

Un unico par discordante — el caso de 23/24 y 55/56 — da exactamente  $p = 0,5$ . Es la demostracion mas limpia posible de que esas campanas no podian separar los brazos, con independencia de lo que hubiera salido.



## 5. Cuando solo sobreviven los marginales

A veces se conserva el total de cada brazo pero no el pareo elemento a elemento, de modo que  $b$  y  $c$  no son recuperables. La salida facil seria descartar la afirmacion; la correcta es **acotarla**.

Los marginales fijan  $b - c$ . Basta recorrer todos los pares  $(b, c)$  compatibles con esa diferencia y quedarse con el **peor** para la significacion: el p-valor resultante es una cota superior valida bajo cualquier pareo consistente con los datos. Si esa cota ya cae por debajo de alfa, la conclusion no depende del pareo perdido.

Es lo que rescata el resultado mas fuerte de la Parte I. En HF contra GGUF los marginales dan  $b - c = 30$ , luego  $c$  esta en  $[0, 15]$ ; el peor caso,  $c = 15$  y  $b = 45$ , todavia da  **$p = 1,3e-04$** . La catastrofe de exportacion es significativa se pareara como se pareara. En `claims.json` se almacenan los  $b$  y  $c$  del peor caso precisamente para que el numero publicado sea la cota, nunca la version favorable.

## 6. Multiplicidad

El repositorio corrio decenas de comparaciones con puerta a lo largo de seis partes. Reportarlas todas sin corregir invita a la objecion evidente: una de cada veinte despeja por azar. Se aplica **Holm-Bonferroni** sobre la familia de afirmaciones con puerta.

Holm y no Bonferroni porque es uniformemente mas potente al mismo error por familia; y no Benjamini-Hochberg porque estas son puertas confirmatorias y no un cribado. Las pruebas indefinidas ( NaN ) quedan **fuera** de la familia: una prueba que no ocurrio no puede consumir alfa.

## 7. Estado de los datos: tres niveles

Cada afirmacion se clasifica por lo que sobrevive en disco, y la clasificacion determina lo que puede decirse de ella.

| Nivel                    | Significa                                                    | Que permite                                                               |
|--------------------------|--------------------------------------------------------------|---------------------------------------------------------------------------|
| <code>per_item</code>    | Existe un registro por elemento con su resultado, y se abrio | Prueba pareada real, IC, recuentos discordantes b y c                     |
| <code>counts_only</code> | Solo sobrevive el agregado del README                        | Prueba a partir de recuentos si el pareo es conocido; sin IC por elemento |
| <code>missing</code>     | No hay datos crudos                                          | <b>Ninguna.</b> Va a la cola de re-ejecucion                              |

Tabla 7.1: Niveles de disponibilidad de datos y que permite afirmar cada uno

Una afirmacion en `missing` no se defiende en el TFM. Se declara como pendiente y se re-ejecuta, o se retira. El registro de re-ejecucion vive en `thesis/rerun-backlog.md` con el comando exacto de cada una.

## 8. Reproducir el analisis

```
.venv-ft/bin/python -m grounding.stats          # auto-  
comprobacion del modulo  
.venv-ft/bin/python -m pytest tests/test_stats.py # 33 aserciones de  
regresion  
.venv-ft/bin/python thesis/run_stats.py        # regenera el  
informe y la figura
```

*Bloque de código 8.1: Comandos que regeneran el analisis completo desde el registro de afirmaciones*

El informe es un derivado: se regenera del registro de afirmaciones y no se edita a mano.