Parte I: puesta en marcha

Índice de contenidos

1. Configuración de la Jetson

2. Primera toma de contacto

3. Referencias

Índice de tablas

Tabla 2.1: Rendimiento, potencia y temperatura de Llama-3.2-3B-Instruct en la Jetson, con el modelo entero en la GPU (ngl 99). El rendimiento es la media ± la desviación típica. La potencia es la de la placa entera (VDD_IN), medida cada segundo.

La primera campaña del proyecto fue una toma de contacto.

El dispositivo de interés es la NVIDIA Jetson Orin Nano Developer Kit, con 8 GB de memoria unificada (de aquí en adelante «la Jetson»).

1. Configuración de la Jetson

Al recibirse, la Jetson no estaba configurada. Se instaló JetPack `6.2.2+b24`, el paquete de *software* de NVIDIA para la Jetson. JetPack incluye el sistema operativo (SO) Jetson Linux, también llamado *Linux for Tegra* (L4T), en su versión `R36.5.0`. La instalación utilizó el proceso manual de reseteo que involucra puentear el inicio para hacerla entrar en modo *Force Recovery* a través de *Universal Serial Bus* (USB), tal y como describe la guía de NVIDIA [1].

El *software flasheado* en la Jetson define dos modos de consumo en `nvpmodel`: 7 W y 15 W. Todas las ejecuciones sobre la Jetson se produjeron con la configuración de 15 W. Para minimizar la variabilidad en las ejecuciones se fijaron los relojes de la Jetson usando el *script* `jetson_clocks` a sus máximos [2]: 6 núcleos de CPU a 1,51 GHz, GPU a 624,75 MHz y *External Memory Controller* (EMC) a 2.133 MHz. Tras la instalación del SO, CUDA detectaba 7.976 MB de memoria unificada, y la Jetson tenía más de 200 GB de almacenamiento *Non-Volatile Memory Express* (NVMe).

2. Primera toma de contacto

El primer experimento realizado buscaba responder a la pregunta: ¿Cuántos *tokens* por segundo da un *large language model* (LLM) en la Jetson, y con qué potencia?

Su resultado da un techo de referencia para los experimentos posteriores.

Se ejecutó el modelo Llama-3.2-3B-Instruct, cuantizado a Q4_K_M, sobre llama.cpp [3] en su *commit* `57fe1f0`, compilado sobre la Jetson para CUDA `sm_87`. Con la herramienta `llama-bench` [4] se midieron las dos fases del proceso de generación: *prefill* (a 512 *tokens*) y *decode* (a 128 *tokens*), en 5 repeticiones. Se midió también un *decode* sostenido de 512 *tokens*, en 3 repeticiones. La potencia y la temperatura se obtuvieron con la herramienta `tegrastats` [5]. La Tabla 2.1 muestra los resultados.

Medida	Valor
Prefill (512 *tokens*)	570,0 ± 2,4 tok/s
Decode (128 *tokens*)	14,61 ± 0,00 tok/s
Decode sostenido (512 *tokens*)	14,53 ± 0,02 tok/s
Potencia en reposo, media	5,24 W
Potencia en *decode*, media	12,5 W
Potencia en *decode*, pico	13,6 W
Temperatura de la unión del *System on Chip* (SoC), pico	66,9 °C
Eficiencia, con el *decode* sostenido y la potencia de pico	1,1 tok/s·W^{-1} (0,94 J/token)

Tabla 2.1: Rendimiento, potencia y temperatura de Llama-3.2-3B-Instruct en la Jetson, con el modelo entero en la GPU (ngl 99). El rendimiento es la media ± la desviación típica. La potencia es la de la placa entera (VDD_IN), medida cada segundo.

3. Referencias

[1] NVIDIA Corporation, "Quick Start," *NVIDIA Jetson Linux Developer Guide, r36.5*. Accedido: 7 nov. 2026. [En línea]. Disponible: https://docs.nvidia.com/jetson/archives/r36.5/DeveloperGuide/IN/QuickStart.html

[2] NVIDIA Corporation, "Jetson Orin Nano Series, Jetson Orin NX Series and Jetson AGX Orin Series," *NVIDIA Jetson Linux Developer Guide, r36.5*. Accedido: 7 nov. 2026. [En línea]. Disponible: https://docs.nvidia.com/jetson/archives/r36.5/DeveloperGuide/SD/PlatformPowerAndPerformance/JetsonOrinNanoSeriesJetsonOrinNxSeriesAndJetsonAgxOrinSeries.html

[3] ggml-org, "llama.cpp, commit 57fe1f0 (b9620)," *GitHub*, jun. 2026. Accedido: 7 nov. 2026. [En línea]. Disponible: https://github.com/ggml-org/llama.cpp/tree/57fe1f07c3b6a1de3f4fff19098e2056a85275b7

[4] ggml-org, "llama.cpp/tools/llama-bench, commit 57fe1f0 (b9620)," *GitHub*, jun. 2026. Accedido: 7 nov. 2026. [En línea]. Disponible: https://github.com/ggml-org/llama.cpp/blob/57fe1f07c3b6a1de3f4fff19098e2056a85275b7/tools/llama-bench/README.md

[5] NVIDIA Corporation, "Tegrastats Utility," *NVIDIA Jetson Linux Developer Guide, r36.5*. Accedido: 7 nov. 2026. [En línea]. Disponible: https://docs.nvidia.com/jetson/archives/r36.5/DeveloperGuide/AT/JetsonLinuxDevelopmentTools/TegrastatsUtility.html